

CLASSIFICAÇÃO COMPUTACIONAL DE LESÕES CUTÂNEAS SUGESTIVAS DE CÂNCER DE PELE UTILIZANDO REDES NEURAIAS CONVOLUCIONAIS E *TRANSFER LEARNING*

COMPUTATIONAL CLASSIFICATION OF SKIN LESIONS SUGGESTIVE OF SKIN CANCER USING CONVOLUTIONAL NEURAL NETWORKS AND *TRANSFER LEARNING*

MARQUES, José Lucas da Silva¹

[Orientador a ser definido]²

RESUMO

O câncer de pele é uma das neoplasias de maior incidência mundial, com crescimento contínuo nas últimas décadas, representando um desafio crescente para a saúde pública em razão do diagnóstico frequentemente tardio e da variabilidade na interpretação de imagens dermatoscópicas entre profissionais de saúde. O presente trabalho tem como objetivo implementar, treinar e comparar arquiteturas de redes neurais convolucionais aplicadas à classificação binária de lesões cutâneas dermatoscópicas sugestivas de câncer de pele, utilizando o *dataset* HAM10000, com vistas a identificar a arquitetura de melhor desempenho como ferramenta auxiliar ao diagnóstico dermatológico computacional. A relevância da pesquisa reside na possibilidade de ampliar o alcance do diagnóstico precoce em contextos com escassez de especialistas e de contribuir para a consolidação de boas práticas em visão computacional aplicada à medicina, especialmente no que tange à explicabilidade dos modelos. A metodologia empregou quatro arquiteturas de *deep learning*, compreendendo CNN *baseline*, ResNet50 com *transfer learning*, ResNet50 com *fine-tuning* e EfficientNetB0, treinadas sobre imagens redimensionadas para 224×224 pixels, com aplicação de aumento de dados, pesos de classe e avaliação por *accuracy*, *precision*, *recall* e *F1-score*. A interpretabilidade das predições foi analisada por meio do Grad-CAM, técnica que gera mapas de ativação sobre as regiões mais relevantes para a decisão da rede. O modelo ResNet50 com *fine-tuning* apresentou o melhor desempenho, alcançando 86% de acurácia, 77% de *recall* para a classe suspeita e *F1-score* de 68%, demonstrando o potencial das redes neurais convolucionais como ferramenta auxiliar ao diagnóstico dermatológico.

Palavras-chave: Câncer de Pele; Redes Neurais Convolucionais; Aprendizado Profundo; Classificação de Imagens Médicas; Interpretabilidade.

ABSTRACT

Skin cancer is one of the most incident neoplasms worldwide, with continuous growth over the last decades, representing a growing public health challenge due to the frequently late diagnosis and the variability in the interpretation of dermoscopic images among health professionals. This study aims to implement, train, and compare convolutional neural network architectures applied to the binary classification of dermoscopic skin lesions suggestive of skin cancer, using the *dataset* HAM10000, in order to identify the best-performing architecture as an auxiliary tool for computational dermatological diagnosis. The relevance of the research lies in the possibility of expanding the reach of early diagnosis in contexts with a shortage of specialists and contributing to the consolidation of best practices in computer vision applied to medicine, particularly regarding model explainability. The methodology

^{1*} Bacharelando em Engenharia de Software pela.

^{2**} Orientador do curso de Engenharia da Computação d.

employed four *deep learning* architectures, including *baseline* CNN, ResNet50 with *transfer learning*, ResNet50 with *fine-tuning*, and EfficientNetB0, trained on images resized to 224×224 pixels, with *data augmentation*, *class weights*, and evaluation by *accuracy*, *precision*, *recall*, and *F1-score*. Model interpretability was analyzed using Grad-CAM, a technique that generates activation maps highlighting the image regions most relevant to the network's decision. The ResNet50 with *fine-tuning* achieved the best performance, reaching 86% *accuracy*, 77% *recall* for the suspicious class, and an *F1-score* of 68%, demonstrating the potential of convolutional neural networks as an auxiliary tool for dermatological diagnosis.

Keywords: Skin Cancer; Convolutional Neural Networks; Deep Learning; Medical Image Classification; Interpretability.

1 INTRODUÇÃO

O câncer de pele figura entre os tumores de maior prevalência mundial (SIEGEL et al., 2022), com estimativas anuais de 185 mil novos casos em território nacional (INCA, 2023). Embora o diagnóstico precoce seja o principal determinante do prognóstico, a triagem dermatoscópica padrão é limitada pela subjetividade e pela escassez de especialistas (ARGENZIANO et al., 2003). A visão computacional oferece uma via para democratizar esse acesso, mas carece de métodos que unam precisão e transparência clínica. Questiona-se, portanto, se arquiteturas convolucionais com aprendizado por transferência podem prover classificações binárias robustas e auditáveis para o suporte médico. Desse modo, busca-se implementar e avaliar comparativamente modelos neurais destinados à classificação de lesões dermatoscópicas, utilizando o HAM10000 como base experimental, a fim de determinar a abordagem de maior acurácia assistencial.

Os objetivos específicos consistem em: (i) pré-processar e balancear o conjunto de dados; (ii) treinar as arquiteturas CNN *baseline*, ResNet50 e EfficientNetB0; (iii) avaliar o desempenho por métricas estatísticas; e (iv) validar a interpretabilidade via Grad-CAM.

A relevância da pesquisa reside na possibilidade de reduzir o tempo de resposta clínica e conferir maior auditabilidade às predições por meio do Grad-CAM, aspecto fundamental para a aceitação médica (TJOA; GUAN, 2021). O compromisso com a ciência aberta é reforçado pela disponibilização pública dos artefatos produzidos. O artigo organiza-se em: fundamentação teórica (Seção 2), metodologia (Seção 3), resultados (Seção 4) e considerações finais (Seção 5).

2 FUNDAMENTOS TEÓRICOS PARA O DIAGNÓSTICO COMPUTACIONAL DE LESÕES CUTÂNEAS

2.1 CÂNCER DE PELE E INTELIGÊNCIA ARTIFICIAL APLICADA À MEDICINA

No âmbito clínico-diagnóstico, o câncer de pele é geralmente classificado em carcinomas, como o basocelular e o espinocelular, que apresentam crescimento mais lento, e melanoma, reconhecido por sua maior agressividade e potencial metastático. A triagem diagnóstica fundamenta-se na regra ABCDE (Assimetria, Bordas, Coloração, Diâmetro e Evolução), cujos critérios foram estabelecidos por Kopf et al. (1994) e estão detalhados no Quadro 1. Contudo, apesar de ser um protocolo historicamente consolidado, a regra ABCDE demonstra limitações inerentes à avaliação visual humana, especialmente diante de lesões atípicas ou em estágios morfológicos incipientes. Essa suscetibilidade ao erro humano e a variabilidade na interpretação interobservador justificam a necessidade de se incorporar modelos computacionais autônomos que transcendam a análise visual clássica e garantam maior homogeneidade diagnóstica.

Quadro 1 – Critérios da regra ABCDE para identificação de lesões cutâneas suspeitas

Critério	Descrição clínica
A – Assimetria	Lesão de conformação irregular, sem eixo de simetria bem definido.
B – Bordas	Margens irregulares, mal delimitadas, recortadas ou com entalhes.
C – Coloração	Heterogeneidade cromática, com presença de múltiplas tonalidades em uma mesma lesão.
D – Diâmetro	Lesões com diâmetro maior que 6 mm merecem atenção clínica, embora melanomas também possam se manifestar em dimensões inferiores.
E – Evolução	Alterações progressivas no tamanho, na forma, na coloração ou na sintomatologia da lesão.

Fonte: Elaborado pelo autor com base em Kopf et al. (1994)

Sob essa perspectiva, sistemas baseados em inteligência artificial favorecem a normatização da avaliação dermatoscópica, mitigando discrepâncias interpretativas e subsidiando a condução diagnóstica em cenários assistenciais de elevada complexidade (BRINKER et al., 2018).


2.2 DEEP LEARNING E REDES NEURAIAS CONVOLUCIONAIS

Por meio das redes neurais convolucionais (CNNs), o *deep learning* possibilita a identificação automática de características morfológicas relevantes diretamente a partir dos dados, dispensando a definição manual de atributos visuais. Esses modelos aprendem representações progressivamente mais complexas, partindo de elementos simples, como bordas e texturas, até padrões mais abrangentes da lesão (GOODFELLOW; BENGIO; COURVILLE, 2016), constituindo a base metodológica da análise dermatoscópica automatizada proposta neste trabalho.

2.3 TRANSFER LEARNING E ARQUITETURAS PROFUNDAS

Com o *transfer learning*, um modelo previamente treinado pode ser reaproveitado e ajustado para analisar imagens médicas. Isso é especialmente relevante porque bases clínicas costumam ser menores e exigem rotulagem especializada, conforme ilustrado na Figura 1.

Figura 1 – Processo de *transfer learning* com *fine-tuning* aplicado a um problema específico



Fonte: Adaptado de Iman, Arabnia e Rasheed (2023)

Arquiteturas pré-treinadas, como ResNet50 e EfficientNetB0, permitem aproveitar representações visuais já aprendidas para acelerar o treinamento e ampliar a capacidade de generalização quando há poucos dados disponíveis. A ResNet50 utiliza conexões residuais para facilitar o aprendizado em redes profundas (HE et al., 2016), enquanto a EfficientNetB0 combina, de maneira equilibrada, o aumento da profundidade, da largura e da resolução da rede (TAN; LE, 2019). Todavia, cabe ressaltar criticamente que tais arquiteturas foram concebidas predominantemente a partir de conjuntos de imagens genéricas (como a ImageNet). Consequentemente, a transposição desses pesos para o domínio oncológico não dispensa a necessidade de uma rigorosa adaptação e curadoria dos dados, pois características cruciais para objetos comuns podem não se traduzir fielmente para as minúcias morfológicas, texturais e de borda típicas de lesões dermatológicas complexas.


2.4 GRAD-CAM E INTERPRETABILIDADE

A incorporação de redes neurais profundas à prática clínica exige mecanismos de interpretabilidade capazes de conferir maior rastreabilidade às inferências

produzidas pelo modelo. A classificação automatizada, portanto, deve estar ancorada em evidências visuais coerentes com os padrões morfológicos examinados.

O *Gradient-weighted Class Activation Mapping* (Grad-CAM) emprega os gradientes das camadas convolucionais terminais para produzir mapas de ativação sobrepostos à imagem dermatoscópica, evidenciando as regiões de maior contribuição para a predição (SELVARAJU et al., 2017), conforme apresentado na Figura 2.

Figura 2 – Imagem dermatoscópica original e respectivo mapa de ativação Grad-CAM gerado pelo modelo ResNet50 com *fine-tuning* aplicado ao *dataset* HAM10000



Fonte: Elaborado pelo autor (2026)

As áreas realçadas por tonalidades quentes, especialmente em vermelho e amarelo, correspondem aos setores de maior influência na inferência do modelo. A resposta de ativação predomina na região central da lesão, marcada por contornos assimétricos, variação cromática e acentuação do contraste, indicando que a rede priorizou atributos morfológicos de relevância clínico-dermatológica.

3 METODOLOGIA

3.1 CLASSIFICAÇÃO DA PESQUISA

Esta pesquisa enquadra-se, quanto à sua natureza, como aplicada, visto que, conforme Silva e Menezes (2001), essa modalidade objetiva produzir conhecimentos passíveis de utilização prática, orientados à resolução de problemas específicos. A elaboração de modelos computacionais voltados à classificação de lesões cutâneas

atende a uma problemática concreta da área médica, reforçando o caráter aplicado da pesquisa.

Quanto à abordagem do problema, a pesquisa classifica-se como quantitativa, uma vez que, conforme Gil (2002), essa perspectiva considera os fenômenos passíveis de mensuração e requer o emprego de recursos estatísticos para classificação e análise dos dados. Os resultados são expressos numericamente por meio das métricas *accuracy*, *precision*, *recall* e *F1-score*, possibilitando comparação objetiva entre as arquiteturas avaliadas.

Em relação aos objetivos, a pesquisa classifica-se como experimental, pois, segundo Gil (2002), essa modalidade delimita um objeto de investigação, seleciona variáveis capazes de influenciá-lo e estabelece procedimentos de controle e observação dos efeitos produzidos. A implementação e a comparação de quatro arquiteturas de redes neurais, aplicadas ao mesmo conjunto de dados sob condições controladas, caracterizam o caráter experimental da pesquisa.

Quanto aos procedimentos técnicos, a pesquisa articula dimensões bibliográficas e experimentais. Conforme Silva e Menezes (2001), a pesquisa bibliográfica desenvolve-se a partir de materiais previamente publicados, incluindo livros e artigos científicos. O embasamento teórico é constituído por literatura especializada em aprendizado profundo, visão computacional e diagnóstico dermatológico assistido por inteligência artificial.

A etapa empírica é conduzida na plataforma Google Colab, ambiente computacional com suporte a GPUs em nuvem, empregando as bibliotecas TensorFlow, Keras, NumPy, Pandas e Scikit-learn.

As atividades a serem desenvolvidas para o cumprimento do objetivo geral obedecem à seguinte sequência cronológica:

1) Aquisição e preparação do conjunto de dados: obtenção do *dataset* HAM10000 via Kaggle e reorganização das sete categorias diagnósticas originais em classificação binária (suspeita / não suspeita).

2) Divisão dos conjuntos: separação das imagens em conjuntos de treinamento (7.010), validação (1.502) e teste (1.503), assegurando distribuição balanceada das classes em cada partição.

3) Pré-processamento: redimensionamento das imagens para 224×224 pixels, normalização para o intervalo $[0, 1]$, aplicação de técnicas de aumento de dados (*data augmentation*), incluindo rotações, deslocamentos, zoom e espelhamento

horizontal, seguido do cálculo dos pesos de classe (*class weights*) para tratamento do desbalanceamento entre classes.

4) Implementação dos modelos: desenvolvimento das quatro arquiteturas de redes neurais convolucionais, abrangendo CNN *baseline*, ResNet50 com *transfer learning*, ResNet50 com *fine-tuning* e EfficientNetB0, todas parametrizadas com função de custo binária, algoritmo de otimização Adam (KINGMA; BA, 2014) e ativação sigmoide na camada final de predição.

5) Treinamento e validação: execução dos ciclos de treinamento com monitoramento das métricas de validação para controle de sobreajuste (*overfitting*) e ajuste dos hiperparâmetros.


6) Avaliação comparativa: cálculo das métricas *accuracy*, *precision*, *recall* e *F1-score* no conjunto de teste, seguido de análise das matrizes de confusão de cada modelo.

7) Aplicação do Grad-CAM: geração dos mapas de ativação sobre a última camada convolucional de cada arquitetura, permitindo análise qualitativa da coerência espacial entre as regiões ativadas e as características morfológicas das lesões.

3.2 DATASET E PROCESSAMENTO DOS DADOS

A base HAM10000 contempla 10.015 imagens dermatoscópicas originalmente distribuídas em sete categorias diagnósticas. Para os fins desta pesquisa, as amostras foram reorganizadas em classificação binária, compreendendo as classes “suspeita”, formada por melanoma, carcinoma e ceratoses, e “não suspeita”, composta por nevos, lesões vasculares, dermatofibromas e queratoses, conforme ilustrado na Figura 3.

Figura 3 – Amostras das sete classes diagnósticas de lesões cutâneas dermatoscópicas presentes no *dataset* HAM10000



Fonte: HAM10000 (2018)

O pré-processamento envolveu o redimensionamento das imagens para 224×224 pixels e a normalização de valores no intervalo $[0, 1]$. A fim de atenuar o sobreajuste e o desbalanceamento inerente ao conjunto, empregou-se a classe *ImageDataGenerator* para aplicação de técnicas de *data augmentation* (incluindo rotações, zoom e espelhamentos) e o cálculo de pesos de classe (*class weights*).

3.3 MODELOS UTILIZADOS

Foram implementadas quatro arquiteturas de redes neurais para avaliação comparativa: uma CNN *baseline* desenvolvida do zero para fins de referência; ResNet50 sob estratégia de *transfer learning* com pesos ImageNet; ResNet50 com *fine-tuning* via descongelamento parcial de camadas convolucionais; e EfficientNetB0, focada em eficiência computacional. Todas as configurações compartilham a função de perda binária, o otimizador Adam (KINGMA; BA, 2014) e a ativação sigmoide na camada de saída, estabelecendo uma base de comparação equitativa entre as diferentes abordagens de aprendizado.

3.4 MÉTRICAS DE AVALIAÇÃO

O desempenho dos modelos é mensurado pelas métricas *accuracy*, *precision*, *recall* e *F1-score* (POWERS, 2011), permitindo uma avaliação quantitativa do comportamento de cada configuração, tanto no desempenho global quanto na capacidade discriminativa entre as classes.

A matriz de confusão (*confusion matrix*) é empregada para examinar, com maior granularidade, a distribuição de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos produzidos por cada modelo, favorecendo a compreensão dos padrões de acerto e erro observados durante o processo classificatório.

3.5 GRAD-CAM

Aplica-se o Grad-CAM (SELVARAJU et al., 2017) às imagens dermatoscópicas classificadas pelos modelos, gerando mapas de calor que evidenciam as regiões de maior contribuição para a decisão da rede neural. A técnica é empregada sobre a última camada convolucional de cada modelo, permitindo comparar a distribuição espacial das ativações entre as configurações avaliadas.

A leitura dos mapas permite verificar se os focos de ativação se concentram nas estruturas da lesão cutânea ou se incidem sobre regiões periféricas sem relevância diagnóstica, contribuindo para a apreciação da confiabilidade, da coerência visual e das limitações de cada modelo.

O trecho a seguir apresenta a implementação simplificada do algoritmo empregado na geração dos mapas de ativação.

Código 1 – Implementação simplificada do Grad-CAM para geração dos mapas de ativação em imagens dermatoscópicas

```
with tf.GradientTape() as tape:
    conv_outputs, predictions = grad_model(img_array)
    loss = predictions[:, 0]
grads = tape.gradient(loss, conv_outputs)
pooled_grads = tf.reduce_mean(grads, axis=(0, 1, 2))
heatmap = conv_outputs[0] @ pooled_grads[..., tf.newaxis]
```

Fonte: Elaborado pelo autor (2026)

4 RESULTADOS E DISCUSSÕES

4.1 COMPARAÇÃO ENTRE OS MODELOS

A Tabela 1 apresenta os resultados obtidos pelos modelos avaliados no conjunto de teste. Observa-se que a CNN *baseline* não detectou nenhuma lesão suspeita, com *recall* e *F1-score* iguais a zero, evidenciando viés total para a classe majoritária. Esse comportamento é esperado em arquiteturas treinadas do zero sobre conjuntos desbalanceados sem estratégias de compensação adequadas, conforme apontado por Brinker et al. (2018). Entre os modelos pré-treinados, a ResNet50 com *fine-tuning* apresentou o melhor desempenho geral, alcançando maior equilíbrio entre *precision*, *recall* e *F1-score*.


Tabela 1 – Comparação das métricas de desempenho entre os modelos avaliados no conjunto de teste

Modelo	Accuracy	Precision	Recall	F1-score
CNN Baseline	0,81	0,00	0,00	0,00
ResNet50 Transfer Learning	0,79	0,47	0,86	0,61
ResNet50 Fine-Tuned	0,86	0,60	0,77	0,68
EfficientNetB0	0,77	0,45	0,79	0,58

Fonte: Elaborado pelo autor (2026)

A Figura 4 apresenta a comparação gráfica entre os modelos implementados. Observa-se que o processo de *fine-tuning* contribuiu significativamente para a melhoria do desempenho da ResNet50 em relação à versão com *transfer learning* simples, permitindo melhor adaptação das representações convolucionais ao domínio das imagens dermatoscópicas, conforme demonstrado por Esteva et al. (2017).

Figura 4 – Comparação das métricas de desempenho entre os modelos avaliados



Fonte: Elaborado pelo autor (2026)

4.2 ANÁLISE DO MODELO RESNET50 FINE-TUNED

O modelo ResNet50 com *fine-tuning* apresentou o melhor desempenho entre as arquiteturas avaliadas, atingindo acurácia de 86%, *recall* de 77% para a classe suspeita e *F1-score* de 68%. O descongelamento parcial das camadas convolucionais permitiu que a rede adaptasse suas representações visuais ao domínio específico das imagens dermatoscópicas do HAM10000, diferenciando-se da versão com *transfer learning* puro, que manteve os pesos da ImageNet integralmente congelados.


O equilíbrio entre sensibilidade e precisão é uma característica essencial em ferramentas de triagem médica. Em aplicações oncológicas, a redução de falsos negativos tem impacto direto na sobrevida dos pacientes, pois lesões malignas não identificadas evoluem para estágios avançados de difícil tratamento. Resultados semelhantes foram relatados por Esteva et al. (2017), cujo modelo CNN atingiu desempenho comparável ao de dermatologistas especializados, evidenciando o potencial clínico dessas arquiteturas. Contudo, é imperativo analisar o *F1-score* de 68% alcançado pelo modelo: embora a alta sensibilidade seja favorável para triagem, a métrica denota uma margem considerável de falsos positivos. Na prática clínica, isso pode sobrecarregar o sistema de saúde com encaminhamentos e biópsias desnecessárias, sugerindo que o modelo atual serve estritamente como um suporte

secundário (*second opinion*) e requer otimização arquitetural antes de uma adoção independente.

4.3 MATRIZ DE CONFUSÃO

A Figura 5 apresenta a matriz de confusão obtida pelo modelo ResNet50 com *fine-tuning* no conjunto de teste. O modelo classificou corretamente 225 verdadeiros positivos e 1.063 verdadeiros negativos, totalizando 1.288 acertos em 1.503 imagens avaliadas. Foram observados 68 falsos negativos e 147 falsos positivos; em aplicações médicas, os falsos negativos representam o ponto mais crítico, pois correspondem a lesões suspeitas classificadas incorretamente como benignas (BRINKER et al., 2018).

Figura 5 – Matriz de confusão do modelo ResNet50 com *fine-tuning* no conjunto de teste



Fonte: Elaborado pelo autor (2026)


4.4 ANÁLISE INTERPRETÁVEL COM GRAD-CAM

A interpretação qualitativa das predições foi realizada mediante aplicação do Grad-CAM às imagens avaliadas pelo modelo ResNet50 com *fine-tuning*, favorecendo a compreensão visual dos padrões considerados pela rede neural.

A Figura 6 apresenta um exemplo de verdadeiro positivo, no qual o modelo concentrou sua atenção sobre regiões pigmentadas e estruturalmente irregulares da

lesão, demonstrando coerência espacial entre a ativação do modelo e as características morfológicas esperadas, como as definidas na regra ABCDE (KOPF et al., 1994).


Figura 6 – Exemplo de verdadeiro positivo: ativação Grad-CAM concentrada sobre a lesão suspeita



Fonte: Elaborado pelo autor (2026)

A Figura 7 apresenta um exemplo de verdadeiro negativo, no qual o modelo classificou corretamente uma lesão não suspeita, apresentando ativação difusa e comportamento consistente com o padrão benigno observado na imagem.


Figura 7 – Exemplo de verdadeiro negativo: baixa ativação Grad-CAM em lesão classificada corretamente como não suspeita



Fonte: Elaborado pelo autor (2026)

A Figura 8 apresenta um caso de falso positivo. Observa-se que o modelo direcionou parte significativa das ativações para regiões externas à lesão, indicando possível influência de padrões espúrios durante o processo de classificação.


Figura 8 – Exemplo de falso positivo: ativação Grad-CAM dispersa em regiões irrelevantes da imagem



Fonte: Elaborado pelo autor (2026)

A Figura 9 apresenta um exemplo de falso negativo, considerado um dos cenários mais críticos em aplicações médicas. O mapa Grad-CAM apresentou ativações difusas e pouco concentradas sobre a lesão, indicando dificuldade do modelo em identificar padrões discriminativos associados à malignidade.

Figura 9 – Exemplo de falso negativo: ativação Grad-CAM insuficiente sobre lesão suspeita não detectada



Fonte: Elaborado pelo autor (2026)

Os resultados dos mapas Grad-CAM evidenciam que o modelo, embora eficaz na maioria dos casos, apresenta limitações interpretáveis: nos falsos positivos, ativa regiões externas à lesão; nos falsos negativos, dispersa a atenção sem foco diagnóstico. Tjoa e Guan (2021) destacam que a interpretabilidade visual é condição necessária para a aceitação de sistemas de inteligência artificial em ambientes clínicos, e os resultados obtidos demonstram que o Grad-CAM cumpre esse papel no

contexto deste experimento. No entanto, de uma perspectiva crítica, a mera sobreposição de mapas de calor não substitui o raciocínio médico estruturado. O Grad-CAM atua estritamente como um mecanismo de transparência técnica para revelar “onde” o modelo focou, mas não consegue explicar o “porquê” da decisão sob o ponto de vista biológico ou fisiopatológico, reafirmando que o julgamento final deve caber ao especialista humano.

5 CONSIDERAÇÕES FINAIS

A presente pesquisa cumpriu o objetivo geral de implementar, treinar e comparar arquiteturas de redes neurais convolucionais voltadas à classificação binária de lesões cutâneas dermatoscópicas, utilizando o *dataset* HAM10000 como base experimental. A configuração de melhor desempenho identificada foi o modelo ResNet50 com *fine-tuning*, que demonstrou equilíbrio superior entre as métricas avaliadas em comparação às demais arquiteturas testadas.

Em relação aos objetivos específicos, o *dataset* HAM10000 foi adequadamente reorganizado em uma formulação binária e submetido a estratégias de compensação do desbalanceamento entre classes, viabilizando condições mais equânimes de treinamento. As quatro configurações propostas, CNN *baseline*, ResNet50 com *transfer learning*, ResNet50 com *fine-tuning* e EfficientNetB0, foram implementadas e avaliadas sistematicamente por métricas de desempenho, evidenciando diferenças expressivas entre abordagens treinadas do zero e modelos submetidos à adaptação ao domínio-alvo. A aplicação do Grad-CAM permitiu verificar que o modelo de melhor desempenho concentrou suas ativações em regiões morfolologicamente relevantes, conferindo maior transparência e auditabilidade ao processo classificatório.

Conclui-se, portanto, que redes neurais convolucionais associadas a estratégias de *transfer learning* e *fine-tuning* apresentam potencial significativo como ferramentas auxiliares à triagem automatizada de lesões cutâneas, contribuindo para a ampliação do diagnóstico precoce, sobretudo em cenários de escassez especializada.

Como limitações do estudo, destacam-se a utilização de um único *dataset* público (HAM10000), o qual apresenta um viés populacional significativo por ser composto majoritariamente por amostras de pacientes europeus de pele clara,

limitando a generalização do modelo para outras etnias e fototipos, e a ausência de validação clínica em ambiente hospitalar real. Para investigações futuras, recomenda-se explorar modelos mais recentes, diversificar a base de dados com imagens de populações etnicamente variadas, adotar estratégias avançadas de balanceamento e conduzir validações clínicas prospectivas voltadas à avaliação da viabilidade real e da aceitabilidade do sistema por profissionais de saúde.

Os códigos-fonte, modelos treinados, notebooks experimentais e demais artefatos computacionais desenvolvidos neste trabalho encontram-se disponíveis publicamente em repositório digital para fins de reprodutibilidade científica. Repositório GitHub: <<https://github.com/marqxctl/skinnet>>. Registro científico (DOI): <<https://doi.org/10.6084/m9.figshare.32311854>>.

REFERÊNCIAS

ARGENZIANO, G. et al. Dermoscopy of pigmented skin lesions: results of a consensus meeting via the Internet. **Journal of the American Academy of Dermatology**, v. 48, n. 5, p. 679-693, 2003.

BRINKER, T. J. et al. Skin cancer classification using convolutional neural networks: systematic review. **Journal of Medical Internet Research**, v. 21, n. 10, e11936, 2018. DOI: 10.2196/11936.

ESTEVA, A. et al. Dermatologist-level classification of skin cancer with deep neural networks. **Nature**, v. 542, p. 115-118, 2017. DOI: 10.1038/nature21056.

GIL, A. C. **Como elaborar projetos de pesquisa**. 4. ed. São Paulo: Atlas, 2002.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. MIT Press, 2016. Disponível em: <<https://www.deeplearningbook.org/>>. Acesso em: maio 2026.

HE, K. et al. Deep residual learning for image recognition. **Proceedings of the IEEE conference on computer vision and pattern recognition**, p. 770-778, 2016.

IMAN, M.; ARABNIA, H. R.; RASHEED, K. A review of deep *transfer learning* and recent advancements. **Technologies**, v. 11, n. 2, p. 40, 2023. DOI: 10.3390/technologies11020040. Disponível em: <https://www.mdpi.com/2227-7080/11/2/40>. Acesso em: maio 2026.

INSTITUTO NACIONAL DE CÂNCER (INCA). **Estimativa 2023: Incidência de Câncer no Brasil**. Rio de Janeiro: INCA, 2023. Disponível em: <<https://www.inca.gov.br/publicacoes/livros/estimativa-2023-incidencia-de-cancer-no-brasil>>. Acesso em: maio 2026.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. **arXiv preprint arXiv:1412.6980**, 2014.

KOPF, A. W.; SALOPEK, T. G.; SLADE, J. Techniques of cutaneous examination for the detection of skin cancer. **Cancer**, v. 75, n. S2, p. 684-690, 1994.

POWERS, D. M. W. Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation. **Journal of Machine Learning Technologies**, v. 2, n. 1, p. 37-63, 2011.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. **Proceedings of the IEEE International Conference on Computer Vision (ICCV)**, p. 618-626, 2017. DOI: 10.1109/ICCV.2017.74.

SIEGEL, R. L. et al. Cancer statistics, 2022. **CA: A Cancer Journal for Clinicians**, v. 72, n. 1, p. 7-33, 2022. DOI: 10.3322/caac.21708.

SILVA, E. L. da; MENEZES, E. M. **Metodologia da pesquisa e elaboração de dissertação**. 3. ed. Florianópolis: UFSC, 2001.

TAN, M.; LE, Q. EfficientNet: Rethinking model scaling for convolutional neural networks. **International conference on machine learning**, p. 6105-6114, PMLR, 2019.

TJOA, E.; GUAN, C. A survey on explainable artificial intelligence (XAI): toward medical XAI. **IEEE Transactions on Neural Networks and Learning Systems**, v. 32, n. 11, p. 4793-4813, 2021. DOI: 10.1109/TNNLS.2020.3027314.

TSCHANDL, P.; ROSENDAHL, C.; KITTLER, H. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. **Scientific Data**, v. 5, p. 180161, 2018. DOI: 10.1038/sdata.2018.161. Disponível em: <https://www.nature.com/articles/sdata2018161>. Acesso em: maio 2026.